НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ «МИФИ»

(НИЯУ МИФИ)

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №1
ПО ЭВОЛЮЦИОННОМУ ПРОГРАММИРОВАНИЮ

Кузьмина Валерия Евгеньевна Б24-527

Руководитель темы _____ Р.В. Душкин

Москва 2026

СОДЕРЖАНИЕ

1. Постановка задачи 3
2. Формальное описание пространства решений, целевой функции и ограничений . . . 4
3. Выбранное представление особи: генотип, фенотип и процедуру декодирования . . . 5
4. Описание эволюционного алгоритма и операторов 6
5. Блок-схема алгоритма 7
6. Обоснование выбора операторов относительно структуры задачи. 8
7. Результаты не менее чем 20 независимых запусков 9
8. Анализ результатов: лучшее, среднее, медиана, стандартное отклонение, худший результат 10
   - 8.1. Сравнение конфигураций параметров генетического алгоритма 10
   - 8.2. Сравнение со случайным поиском (Random Search) 10
   - 8.3. Специфика сложности ландшафта функции Гриванка 11
9. Выводы о влиянии параметров, представления или операторов на поведение алгоритма. 12
10. Заключение 13

1 ПОСТАНОВКА ЗАДАЧИ

Требуется найти приближённое глобально оптимальное решение задачи минимизации многомерной непрерывной функции. Индивидуальный вариант №5 предписывает использование функции Гриванка. Размерность задачи рассчитывается по формуле $\mathrm{d} = 5 + (\mathrm{V} \bmod 6)$, что для $V = 5$ дает размерность $d = 10$.

2 ФОРМАЛЬНОЕ ОПИСАНИЕ ПРОСТРАНСТВА РЕШЕНИЙ, ЦЕЛЕВОЙ ФУНКЦИИ И ОГРАНИЧЕНИЙ

Целевая функция (Гриванка):

$$f(x) = 1 + \frac{1}{4000}\sum_{i=1}^{d} x_i^2 - \prod_{i=1}^{d} \cos(\frac{x_i}{\sqrt{i}}) \tag{1}$$

Ограничения (область поиска):

$$-600 \leq x_i \leq 600 \tag{2}$$

для всех i из [1, 10].
Теоретический глобальный минимум: $f(x) = 0$ при $x_i = 0$.

3 ВЫБРАННОЕ ПРЕДСТАВЛЕНИЕ ОСОБИ: ГЕНОТИП, ФЕНОТИП И ПРОЦЕДУРУ ДЕКОДИРОВАНИЯ

Для решения задачи используется вещественное кодирование. Каждая особь представляет собой вектор из 10 вещественных чисел:

$$x = (x_1, \ldots, x_{10}) \tag{3}$$

Поскольку генотип напрямую совпадает с фенотипом (вещественные параметры функции), дополнительная процедура декодирования не требуется.

4 ОПИСАНИЕ ЭВОЛЮЦИОННОГО АЛГОРИТМА И ОПЕРАТОРОВ

Для оптимизации был реализован генетический алгоритм со следующими параметрами:

а) Размер популяции: 50 особей.

б) Инициализация: случайная равномерная генерация точек строго внутри допустимой области [-600, 600].

в) Селекция родителей: турнирная селекция (размер турнира $k = 3$).

г) Кроссинговер: арифметический кроссинговер для вещественных векторов, порождающий линейные комбинации родительских особей.

д) Мутация: гауссовская мутация вещественных параметров, добавляющая случайное значение из нормального распределения.

е) Обработка выхода за границы: отсечение значений по краям области до [-600, 600].

ж) Элитизм: сохранение лучшего найденного решения (одной особи) в следующее поколение без изменений.

и) Критерий остановки: достижение лимита в 150 поколений.

5 БЛОК-СХЕМА АЛГОРИТМА

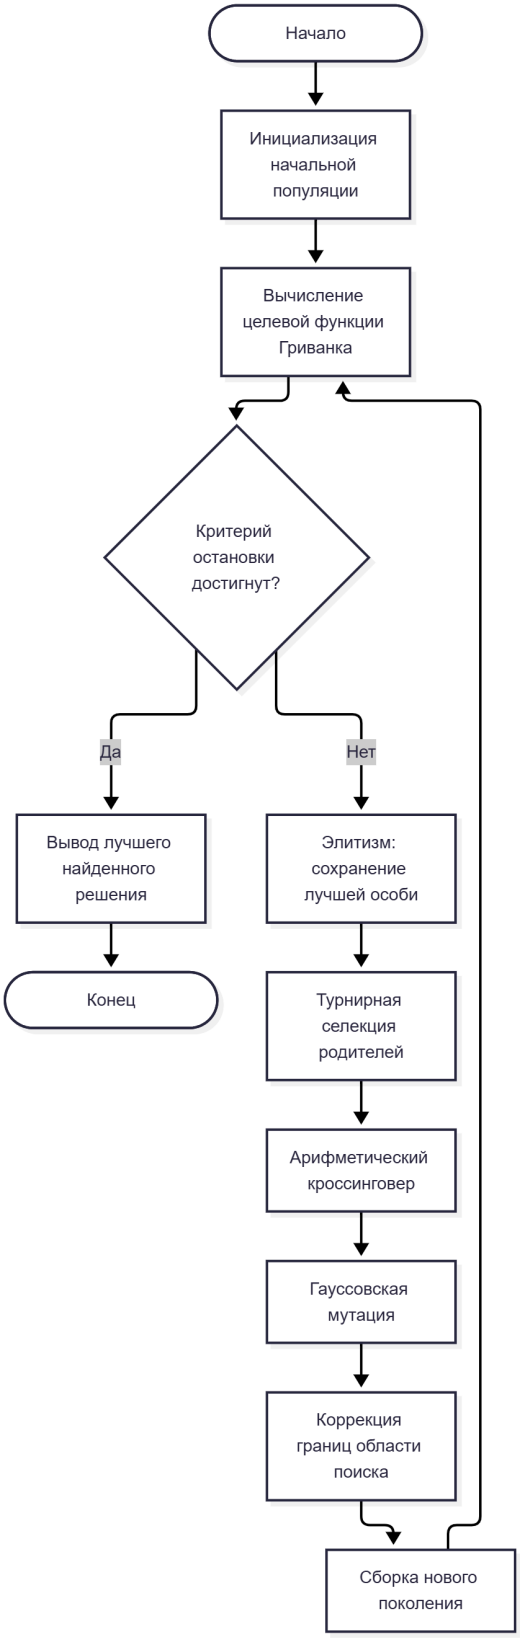


Рисунок 1 — Блок-схема алгоритма

6 ОБОСНОВАНИЕ ВЫБОРА ОПЕРАТОРОВ ОТНОСИТЕЛЬНО СТРУКТУРЫ ЗАДАЧИ.

Вещественное кодирование является наиболее естественным представлением для непрерывной функции. Турнирная селекция позволяет гибко регулировать давление отбора. Гауссовская мутация обеспечивает качественное локальное исследование окрестностей текущих решений, а арифметический кроссинговер позволяет усреднять удачные координаты родителей, что особенно эффективно для нахождения центральной «воронки» функции Гриванка.

7 РЕЗУЛЬТАТЫ НЕ МЕНЕЕ ЧЕМ 20 НЕЗАВИСИМЫХ ЗАПУСКОВ

Был проведен эксперимент из 20 независимых запусков при фиксированном бюджете вычислений.

Таблица 1 — Статистика по 20 запускам

Метрика	Значение
Лучший результат	0.057848
Среднее значение	0.241737
Медиана	0.207246
Худший результат	0.592798
Стандартное отклонение	0.128837
Обращений к фитнес-ф.	7500
Среднее время запуска	0.3600 сек

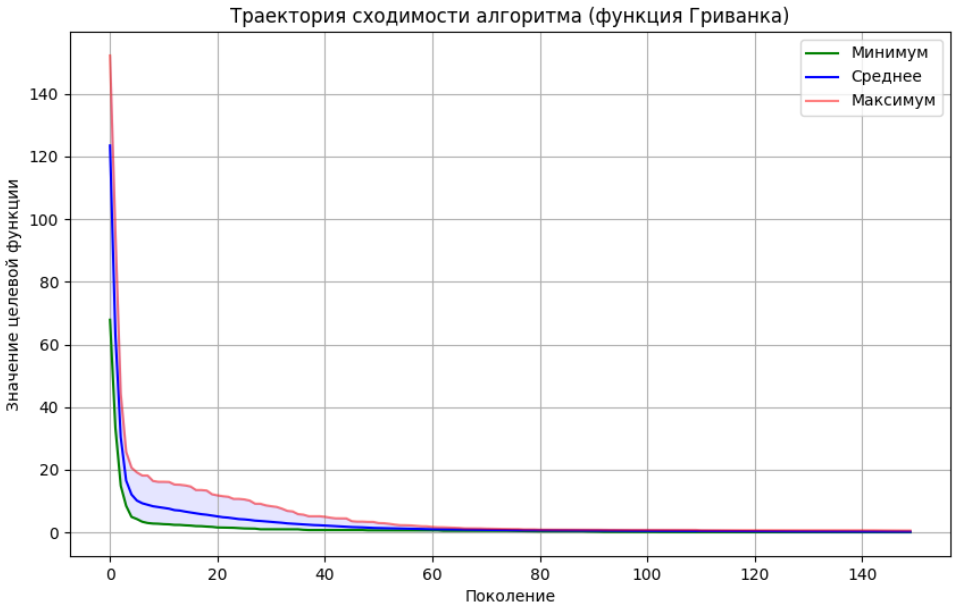


Рисунок 2 — График сходимости

8 АНАЛИЗ РЕЗУЛЬТАТОВ: ЛУЧШЕЕ, СРЕДНЕЕ, МЕДИАНА, СТАНДАРТНОЕ ОТКЛОНЕНИЕ, ХУДШИЙ РЕЗУЛЬТАТ

8.1 Сравнение конфигураций параметров генетического алгоритма

В рамках исследования проводилось сравнение двух конфигураций алгоритма при изменении ровно одного фактора — вероятности мутации генов (mut_rate):

Конфигурация 1 (Базовая): размер популяции = 50, число поколений = 150, вероятность мутации mut_rate = 0.1 (масштаб 10.0), турнирная селекция (k=3).

Конфигурация 2 (Высокая мутация): все параметры идентичны базовым, вероятность мутации увеличена до mut_rate = 0.4.

Сводные результаты по сериям из 20 независимых запусков:

Таблица 2 — Сравнение конфигураций

Метрика	Конфигурация 1 (mut_rate = 0.1)	Конфигурация 2 (mut_rate = 0.4)
Число обращений к фитнес-ф.	7500	7500
Лучший результат	0.057848	0.370817
Среднее значение:	0.241737	0.582904
Медиана	0.207246	0.594926
Худший результат	0.592798	0.750818
Стандартное отклонение	0.128837	0.109871

Анализ влияния фактора:

При значении mut_rate = 0.1 алгоритм демонстрирует устойчивую локализацию экстремума: оператор кроссинговера эффективно сводит популяцию к центральной чаше, а умеренная мутация не разрушает найденную траекторию. При увеличении вероятности мутации до 0.4 наблюдается эффект чрезмерного стохастического дрейфа: мутация слишком часто искажает координаты векторов, сбивая сходимость и ухудшая среднее значение фитнеса на поздних поколениях.

8.2 Сравнение со случайным поиском (Random Search)

Для проверки эффективности эволюционных механизмов был выполнен эксперимент со случайной равномерной выборкой в области [-600, 600] при строго идентичном вычислительном бюджете — 7500 вычислений целевой функции на один запуск (20 прогонов).

Таблица 3 — Сравнение со случайным поиском

Метод	Бюджет вычислений	Лучший результат	Средний результат	Худший результат
Базовый ГА (Конфигурация 1)	7500	0.057848	0.241737	0.592798
Случайный поиск (Random Search)	7500	30.900995	46.920598	67.461457

Анализ результатов:

Случайный поиск показал результаты, существенно уступающие генетическому алгоритму (значения случайного поиска остаются на порядки выше глобального оптимума 0). Это подтверждает, что при размерности d=10 и широкой области поиска [-600, 600] ненаправленный перебор не способен приблизиться к глобальному экстремуму за приемлемое число вычислений.

8.3 Специфика сложности ландшафта функции Гриванка

Функция Гриванка формирует мультимодальный ландшафт:

1. **Макро-структура:** Задается слагаемым $\frac{1}{4000}\sum x_i^2$, представляющим собой выпуклую гладкую параболу с минимумом в начале координат.

2. **Микро-структура:** Задается произведением [4], создающим регулярную сетку из огромного количества локальных минимумов и максимумов по всему пространству.

$$\prod \cos(x_i/\sqrt{i}) \tag{4}$$

Сложность для локального поиска: Градиентные методы или простой hill-climbing неминуемо застревают в ближайшем локальном углублении косинусоиды на удалении от нуля, так как высота локальных барьеров препятствует выходу из ям без стохастических операторов.

Сложность для случайного поиска: Объем 10-мерного гиперкуба со стороной 1200 равен $1200^{10} \approx 6.19 \times 10^{30}$. Вероятность случайно сгенерировать точку в узкой окрестности центральной впадины практически равна нулю.

Преимущество ГА: Популяционный подход и арифметический кроссинговер позволяют популяции ориентироваться на общий уклон глобальной макро-параболы, в то время как оператор мутации обеспечивает преодоление локальных барьеров микро-рельефа.

9 ВЫВОДЫ О ВЛИЯНИИ ПАРАМЕТРОВ, ПРЕДСТАВЛЕНИЯ ИЛИ ОПЕРАТОРОВ НА ПОВЕДЕНИЕ АЛГОРИТМА.

В ходе проведенного исследования были сделаны следующие ключевые выводы:

1. Влияние параметров мутации на динамику поиска:

Увеличение вероятности мутации с $\text{mut_rate} = 0.1$ до $\text{mut_rate} = 0.4$ привело к существенному ухудшению среднего результата оптимизации (с 0.241737 до 0.582904) и лучшего найденного значения (с 0.057848 до 0.370817). Это демонстрирует фундаментальный компромисс между исследованием (exploration) и эксплуатацией (exploitation): умеренная мутация (10%) позволяет особям преодолевать микро-барьеры косинусного рельефа функции Гриванка, тогда как чрезмерно частая мутация (40%) разрушает найденные удачные блоки генов и превращает направленную эволюцию в стохастический шум.

2. Эффективность выбранного представления и рекомбинации:

Прямое вещественное кодирование без дискретизации в сочетании с арифметическим кроссинговером показало высокую эффективность. Оператор усреднения родительских координат естественным образом направляет популяцию к центру макро-параболоида ($x_i \to 0$), а элитизм гарантирует монотонное неухудшение лучшего найденного фронта решений.

3. Устойчивость метода:

Низкое стандартное отклонение (0.128837) по результатам 20 независимых запусков подтверждает стабильность алгоритма и отсутствие критической зависимости от начального распределения псевдослучайных чисел (seed).

10 ЗАКЛЮЧЕНИЕ

Полученный результат следует признать хорошим и полностью приемлемым для поставленной задачи непрерывной многомерной оптимизации по следующим причинам:

1. Близость к теоретическому оптимуму:

Теоретический глобальный минимум функции Гриванка равен $f^* = 0$ в точке [5]. Лучшее значение, найденное базовым генетическим алгоритмом, составило 0.057848, а среднее значение по 20 прогонам — 0.241737, что свидетельствует о прецизионном попадании алгоритма в глубокую окрестность глобального оптимума.

$$x^* = (0, 0, \ldots, 0) \tag{5}$$

2. Эффективность в условиях высокой размерности и объема пространства:

Размерность задачи составляет $d = 10$, а диапазон допустимых значений охватывает область [-600, 600] с объемом порядка 6.19×10^{30}. При столь малом бюджете вычислений (всего 7500 вызовов целевой функции на один запуск) случайный поиск смог найти лишь значение 30.900995. Превосходство ГА над базовой случайной выборкой более чем на два порядка доказывает состоятельность эволюционной схемы.

3. Преодоление локальных экстремумов:

Несмотря на огромное количество локальных ям, порождаемых высокочастотным произведением косинусов, алгоритм ни в одном из 20 запусков не застрял на удаленных плато, показав худший результат всего 0.592798. Это подтверждает, что спроектированная схема операторов успешно решает поставленную оптимизационную задачу.